OVERVIEW
Tabla resumen 28
Criterios de aceptación
A · GOVERNANCE (11)
A1 · Inventario de datos D1-5
A2 · Clasificación PII D3-7
A3 · Data Contract C→M D5-10
A4 · Data Contract M→P D5-10
A5 · Política RBAC D7-12
A6 · Schema Registry D8-12
A7 · Diccionario Gold D10-15
A8 · SLA por campo D10-15
A9 · Audit log PII D12-15
A10 · Sign-off CAPECO D1→15
A11 · Linaje de datos D15-20
B · DATA LAKE (9)
B1 · Infra Azure ADLS D1-5
B2 · Capa Bronze D5-12
B3 · Pipeline Br→Si D10-17
B4 · Capa Silver D12-18

// PME CAPECO · Sprint 1 · Entregables técnicos · Días 1–20

# 28 entregables para cerrar Governance + Data Lake + Agentes

Cada entregable tiene número, dueño, día de entrega, criterio de aceptación (DoD) y dependencias. Están ordenados por el plan de 60 días. Ninguno es opcional para la demo ante CAPECO el Día 60.

📋 **11 entregables Governance · Días 1–20**

🗄️ **9 entregables Data Lake · Días 1–20**

🤖 **8 entregables Agentes · Días 12–52**

**Total: 28 entregables · Equipo: 10 personas**

🚨 **Dependencia crítica del plan:** El entregable A10 (Sign-off CAPECO sobre uso comercial de TELEFONO CONSTRUCTOR) bloquea la capa Gold de PME Proveedores. Se inicia el Día 1 y debe cerrarse antes del Día 15. Si no llega, PME Proveedores sale sin ese campo en la demo y se añade post-Día 60. El resto del plan no se bloquea.

RESUMEN EJECUTIVO

## Los 28 entregables de un vistazo

Ordenados por sprint day. Los entregables en negrita son bloqueantes para los que siguen.

| # | ENTREGABLE | OW |
|---|---|---|
| A1 | **Inventario completo de campos BD** | D |
| A2 | **Clasificación PII por nivel** | D |

| | | |
|---|---|---|
| | | |
| A10 | Sign-off CAPECO (TELEFONO CONSTRUCTOR) | P |
| B1 | Infraestructura Azure ADLS Gen2 | D |
| C1 | Diseño arquitectura de agentes | D<br>F |
| A3 | Data Contract CAPECO → MIS | D<br>P |
| A4 | Data Contract MIS → PME Proveedores | D<br>P |
| B2 | Capa Bronze operativa | D |
| B7 | API REST interna (Gold Layer) | F<br>F |
| A5 | Política y roles RBAC | F<br>P |
| A6 | Schema Registry | D |

| | | |
|---|---|---|
| | (Gold) | |
| B8 | Snapshots trimestrales inmutables | D |
| A7 | Diccionario de datos (lenguaje negocio) | D |
| A8 | SLA de calidad por campo | D<br>D |
| B3 | Pipeline Bronze → Silver | D |
| B9 | Dashboard admin de governance | F |
| A9 | Audit log de acceso a campos PII | F |
| B4 | Capa Silver validada | D<br>Q |
| C2 | DataQualityAgent v1 | D<br>D |

| | | |
|---|---|---|
| | | |
| C3 | NormalizationAgent v1 | F |
| B5 | Pipeline Silver → Gold | D |
| A11 | Linaje de datos (automático) | F |
| C4 | LineageAgent v1 | F |
| B6 | Capa Gold certificada | D<br>Q |
| C5 | Orquestador de agentes | F<br>D |
| C6 | Test suite de agentes | Q<br>Q |
| C7 | AlertAgent v1 (Sprint 2) | D |

| | | |
|---|---|---|
| C8 | **ReportAgent v1 (Sprint 3)** | D<br>D |

CRITERIOS DE ACEPTACIÓN GLOBALES

## Definition of Done del Sprint 1

Un entregable está Done cuando cumple TODOS estos criterios, no cuando el código compila.

**✅ Para entregables de Governance**

Documento firmado o aprobado por dueño del dato
Disponible en Confluence/Notion del proyecto
Revisado por PM + DE + representante CAPECO si aplica
Sin campos sin owner asignado
Versionado con fecha y autor

**✅ Para entregables de Data Lake**

Pipeline corre sin errores en staging
QA valida que Bronze = fuente original (sin pérdidas)
QA valida que Silver no expone PII de nivel 1/2
Tiempo de ejecución documentado y dentro de SLA
Snapshot versionado

con hash SHA256

✅ **Para entregables de Agentes**

Agente tiene inputs, outputs y trigger documentados
Test unitarios con cobertura >80%
Agente falla de forma controlada (no bloquea el pipeline)
Genera log estructurado en JSON por ejecución
QA valida casos borde: dato corrupto, campo vacío, GPS fuera de Lima

✅ **Para la demo Día 60**

Cada entregable demostrable en <2 minutos
Datos reales de la BD (cero datos ficticios en la demo)
Rehearsal completo el Día 50 con todo el equipo
Guión técnico y ejecutivo validados por DA + PM
Ambiente de producción freeze desde Día 55

---

A · GOVERNANCE · 11 ENTREGABLES · DÍAS 1–20

## Gobernanza de la información CAPECO

El governance no es burocracia — es lo que hace que los agentes confíen en los datos que procesan y que CAPECO confíe en lo que MIS hace

con su BD.

ℹ️ **Punto de partida real:** La BD tiene 150 columnas en `data_capeco_full`. Algunas tienen espacios en el nombre (requieren backtick quoting). MARCA_PINTURA_1 tiene 0% de completitud. MARCA_SANITARIO tiene 100% de registros pero 85% dice "No precisan". Esos son los problemas que el governance debe documentar y resolver antes de que cualquier agente procese esos campos.

A1

### Inventario completo de campos BD CAPECO

📋

Auditoría de las 150 columnas de data_capeco_full: tipo, completitud real, valores frecuentes y descripción de negocio.

**Días 1-5**

**DA** Data Analyst

**DoD: spreadsheet aprobado por DE + PM**

### CONTENIDO DEL ENTREGABLE

- Nombre exacto de columna (con espacios tal cual en MySQL)
- Tipo de dato en MySQL (varchar, int, float, datetime)
- % completitud real Q4 2025 (ejecutado con query COUNT vs total)
- Top 5 valores más frecuentes con conteo
- Descripción en lenguaje de negocio (no técnico)
- Clasificación preliminar: Core / Enriquecimiento / PII / Excluido

### CAMPOS CRÍTICOS YA IDENTIFICADOS (RESULTADO ESPERADO)

```
# Completitud conocida de campos clave (2025, 38,744 registros) FASE → 100% Core X / Y (GPS) → 100% Core BANCO → 100% Core NRO_PISOS → 99.9% Core AREA_CONSTRUCCION → 99.5% Core TELEFONO CONSTRUCTOR → 91.8% PII-1 · requiere sign-off MARCA_SANITARIO → 100% reg / 14.8% útil Enriq. MARCA_PINTURA_1 → 0% Excluido v1 MARCA_DRYWALL → 74.9% Enriq.
```

HERRAMIENTAS

- Script Python sobre Azure MySQL (query_pme.py existente como base)
- Claude API para generar descripciones de negocio a partir de los valores frecuentes
- Google Sheets o Notion para el inventario colaborativo

A2

## Clasificación PII por nivel de sensibilidad

Asignar a cada campo un nivel PII (0 = público / 1 = restringido / 2 = confidencial) con la restricción de acceso correspondiente por producto.

Días 3–7

DE1 PM

DoD: aprobado por CAPECO legal + firmado

NIVELES PII DEFINIDOS PARA EL PROYECTO

- **PII-0 (Público):** FASE, GPS, PRECIO_X_M2, NRO_PISOS, BAN MARCA_PORCEL → disponible en ca Gold sin restricció
- **PII-1 (Restringido):** NOMBRE DEL CONSTRUCT TELEFONO CONSTRUCT NOMBRE PROPIETARIC solo accesibl el producto tiene autorización explícita CAPECO
- **PII-2 (Confidencial):** TELEFONO PROPIETARI datos de personas naturales → solo en capa Bronze, nunc en producto
- **Excluido:** MARCA_PINTURA_ (0% completitud), campos de encuesta interna sin valor comercial

### MATRIZ DE ACCESO POR PRODUCTO

```
Producto PII-0 PII-1
PII-2 PME CAPECO SI NO
NO PME Proveedores SI
COND* NO Tasamelo SI
NO NO API Externa SI
NO NO Admin interno SI
SI SI (Bronze only) *
```

COND = condicional a sign-off A10 firmado

A3

### Data Contract: CAPECO → MIS (ingesta trimestral)

Contrato formal que define cómo CAPECO entrega la data a MIS cada trimestre. Schema, formato, SLA de entrega y responsabilidades.

Días 5–10

DE1 PM

DoD: firmado por ambas partes antes del Día 12

CLÁUSULAS OBLIGATORIAS DEL CONTRATO

- **Schema comprometido:** Lista de columnas, tipos y reglas de validación que CAPECO garantiza en cada entrega

entrega

| | |
|---|---|
| **SLA de entrega:** | Máximo 15 días calendario después del cierre de cada trimestre (Q1→15 abr, Q2→15 jul, Q3→15 oct, Q4→15 ene) |
| **Formato de entrega:** | Dump MySQL comprimido o acceso directo a Azure MySQL — a definir en el contrato |
| **Notificación de cambios de schema:** | CAPECO notifica con 30 días de anticipación si agrega o elimina columnas |
| **Registro histórico:** | MIS conserva cada entrega trimestral como snapshot inmutable mínimo 7 años |
| **Uso permitido:** | Operación de plataformas PME CAPECO, PME Proveedores y Tasamelo bajo marca MIS×CAPECO |

A4

## Data Contract: MIS → PME Proveedores (uso comercial)

Define exactamente qué campos del Gold Layer puede usar PME Proveedores, bajo qué condiciones y con qué restricciones legales.

**Días 5–10**

**DE1** **PM**

**DoD: firmado por MIS legal. Referencia A10 si incluye PII-1**

**CAMPOS AUTORIZADOS EN PME PROVEEDORES (VERSIÓN SIN SIGN-OFF A10)**

```
# Campos Gold disponibles SIN sign-off CAPECO (PII-0)
NOMBRE DEL PROYECTO, FASE, PCT_AVANCE, SUB_FASE NRO_PISOS, AREA_CONSTRUCCION, NRO_UNIDADES X, Y, DIRECCION, DISTRITO, URBANIZACION BANCO, BANCO_1, BANCO_2 MARCA_SANITARIO, MARCA_PORCELANATO, MARCA_DRYWALL TECHOS,
```

```
PAREDES, PISOS
ASCENSOR_TIENE,
SISTEMA_GAS ANIO, TRIM
# Campos que requieren
A10 firmado (PII-1)
NOMBRE DEL CONSTRUCTOR
TELEFONO CONSTRUCTOR
CONSTRUCTOR_DIRECCION
```

**RESTRICCIONES DE USO**

- Los datos solo pueden mostrarse agregados o por proyecto — no exportar listados masivos de teléfonos
- El suscriptor de PME Proveedores no puede re-vender ni re-distribuir los datos
- Logs de acceso por suscriptor requeridos para auditoría CAPECO

A5

### Política y roles RBAC (Role-Based Access Control)

Define los 4 roles del sistema y qué puede hacer cada uno. Implementado en la API interna desde el Día 12.

**Días 7-12**

**FS3** **PM**

**DoD: QA verifica que PME Proveedores NO**

accede a PII-1
sin A10

### ROLES Y PERMISOS

Role: admin-mis Acceso: ALL capas (Bronze, Silver, Gold) + PII-0/1/2 Personas: equipo técnico MIS Role: analista-mis Acceso: Silver + Gold. PII-0 y PII-1 con log de acceso Personas: DA, PMs Role: pme-

capeco Acceso: Gold solo. PII-0. Sin PII-1 ni PII-2 Personas: suscriptores PME CAPECO Role: pme-proveedores Acceso: Gold subset aprobado en A4. PII-1 solo si A10 firmado Personas: suscriptores PME Proveedores

### IMPLEMENTACIÓN TÉCNICA (FS3)

- JWT tokens con claims de role asignados en el login
- Middleware en FastAPI/Node que valida role vs campo solicitado
- Tabla de permisos en base de datos — no hardcodeada en código
- Audit log: cada acceso a campo PII-1 genera entrada en tabla

audit_log

A6

### Schema Registry de la capa Gold

Registro versionado de cada campo Gold: tipo, descripción, owner, SLA y versión de schema.

Días 8–12 DE1

DoD: 100% de campos Gold con owner asignado y tipo validado

- Formato: JSON Schema o Apache Avro — compatible con Azure Data Lake
- Cada campo: nombre, tipo, nullable, descripción, owner, SLA_completitud, pii_level, version
- Versionado semántico: v1.0.0 al inicio, v1.x.0 si CAPECO agrega campos, v2.0.0 si cambia tipos
- Almacenado en el contenedor Gold como archivo schema.json inmutable por versión
- Alertas automáticas si schema cambia entre cargas (LineageAgent C4 lo monitorea)

A7

### Diccionario de datos en lenguaje de negocio

📖

Traducción de cada campo técnico a lenguaje entendible por CAPECO, los comerciales de MIS y los suscriptores.

Días 10–15 DA

DoD: revisado por PM + aprobado por referente CAPECO

Ejemplo de entrada del diccionario: Campo técnico: PRECIO_X_M2 Nombre negocio: "Precio de cierre por m² (soles)" Descripción: "Precio real al que se vendió cada unidad dividido entre el área techada. Es el precio de cierre, no el precio de lista." Ejemplo: 8417.5 (S/ 8,417.5 por m² en Miraflores Q4 2025) Restricción: Ninguna. Campo público PII-0. Fuente: Calculado por MIS a partir de PRECIO_SOLES

/ AREA_X_UNIDAD

- Generado con apoyo de Claude API: DA sube el inventario A1 y Claude genera las descripciones en lenguaje de negocio
- DA revisa y corrige — Claude hace el 80% del trabajo, DA hace el 20% de revisión
- Publicado en Confluence/Notion accesible para todo el equipo y para CAPECO

A8

### SLA de calidad por campo Gold

Umbral mínimo aceptable de completitud y regla de validación para cada campo crítico. Si no se cumple, el DataQualityAgent bloquea el paso a Gold.

Días 10-15

DE1 DA

DoD: SLAs definidos para todos los campos Core

SLAs para campos Core (ejemplos): FASE → completitud > 99%

completitud ≥ 99% · valores válidos: lista cerrada X / Y → completitud = 100% · bounding box Lima (-77.2 a -76.7, -12.5 a -11.5) NRO_PISOS → completitud ≥ 99% · rango: 1–60 PRECIO_X_M2 → completitud ≥ 75% (obras activas) · rango: S/1,000–S/25,000 AREA_CONSTRUCCION → completitud ≥ 99% · rango: 50–50,000 m² BANCO → completitud = 100% · lista blanca de bancos Perú MARCA_PORCELANATO → completitud ≥ 20% con marca real (excluyendo "No tienen") MARCA_SANITARIO → completitud ≥ 14% con marca real (excluyendo "No precisan")

A9

### Audit log de acceso a campos PII

Sistema de registro de auditoría que captura cada acceso a campos PII-1 y PII-2 con usuario, timestamp, query

ejecutada y justificación.

Días 12–15

FS3

DoD: QA verifica que acceso a TELEFONO CONSTRUCTOR queda registrado

- Tabla `audit_log`: user_id, campo_a pii_level, timestam query_ha ip_addre
- Inmutable: no se puede borrar ni editar — append-only
- Reporte semanal automático al PM: qué campos PII fueron accedidos y por quién
- CAPECO puede solicitar auditoría en cualquier momento — este log es la evidencia

A10

### Sign-off CAPECO · Uso comercial de TELEFONO CONSTRUCTOR

⚖️

Documento legal firmado por CAPECO

CAPECO autorizando a MIS exponer el campo TELEFONO CONSTRUCTOR en PME Proveedores como dato de prospección comercial.

Días 1 → 15 (iniciado D1)

PM + Legal
CAPECO + Legal
MIS

DoD: documento firmado físico o digital con valor legal

⚠️ **Este es el único entregable que no depende del equipo técnico.** Depende de los tiempos legales de CAPECO. Se inicia el Día 1. Si no llega antes del Día 15, PME Proveedores sale en la demo sin ese campo — el plan no se paraliza.

→ Sección 1: descripción del

- Sección 1: descripción del campo y su uso en PME Proveedores
- Sección 2: restricciones de uso (no re-venta, no exportación masiva, logs de acceso)
- Sección 3: derechos de CAPECO para auditar el uso en cualquier momento
- Sección 4: vigencia y condiciones de revocación
- Firmado por: Representante Legal CAPECO + Gerente General MIS

A11

### Linaje de datos automatizado

Sistema que permite trazar el origen de cualquier valor Gold hasta su fuente original en el formulario CAPECO de campo.

Días 15-20

FS2 implementa · DE1 define reglas

DoD: dado un valor en Gold se puede rastrear hasta Bronze en <3 clicks

- Ejemplo de consulta: "¿de dónde viene el precio m² de este proyecto?" → Respuesta: "PRECIO_SOLES / AREA_X_UNIDAD, Bronze snapshot Q4-2025, cargado el 2026-04-05"
- Implementado como parte del LineageAgent C4 — misma base de código
- Visible en el dashboard admin B9 para CAPECO
- Responde en lenguaje natural vía PME Copilot (Sprint 3)

B · DATA LAKE · 9 ENTREGABLES · DÍAS 1-20

## Arquitectura Azure Data Lake · Bronze / Silver / Gold

El Data Lake no reemplaza el Azure MySQL de CAPECO — se construye encima. El MySQL sigue siendo la fuente de verdad. El lake agrega capas de calidad, versionado y acceso controlado.

🏗️ **Arquitectura sobre lo que ya existe:** millennialprod.mysql.database.azure.com permanece como fuente primaria. Azure Data Lake Storage Gen2 (ADLS) se provisiona en la misma suscripción Azure de MIS. Los scripts Python actuales (query_pme.py, query_obras.py) seguirán funcionando — solo cambiarán para leer desde la API interna (B7) en lugar de MySQL directo.

B1

### Infraestructura Azure ADLS Gen2 ☁️

Provisionamiento de Azure Data Lake Storage Gen2 con los 3 contenedores, permisos IAM y configuración de retención.

Días 1–5 DE2

DoD: 3 contenedores creados · DE1 puede leer/escribir · QA verifica permisos

ESTRUCTURA DE CONTENEDORES

```
Storage Account: pme-datalake-prod
Container: bronze/
capeco/ raw/
year=2025/trimestre=Q4/
data_capeco_full_Q4_2025.
← snapshot inmutable
```

```
Container: silver/
capeco/ cleaned/
year=2025/trimestre=Q4/
obras_silver_Q4_2025.parq
Container: gold/ pme-
capeco/ ← campos para
PME CAPECO pme-
proveedores/ ← campos
autorizados para PME
Proveedores schema/
schema_v1.0.0.json
```

**CONFIGURACIÓN REQUERIDA**

- Hierarchical Namespace habilitado (requerido para ADLS Gen2)
- IAM: rol Storage Blob Data Contributor para la cuenta de servicio de los pipelines
- Soft delete habilitado: retención mínima 90 días
- Lifecycle management: Bronze → tier Archive después de 1 año
- Private endpoint: solo accesible desde la red virtual de MIS — no público

B2

### Capa Bronze — Snapshot raw de CAPECO

🟤

Copia exacta e inmutable de data_capeco_full en el Data Lake. Incluye TODOS los

incluye TODOS los campos, incluyendo PII. Primera fuente de verdad del lake.

**Días 5–12** **DE2**

**DoD: QA verifica COUNT(*) Bronze = COUNT(*) MySQL · hash SHA256 generado**

### PIPELINE DE INGESTA BRONZE (PYTHON)

```
# bronze_ingesta.py — ejecutado por DE2
import mysql.connector, pandas as pd from azure.storage.filedatalak
import DataLakeServiceClient
import hashlib, json
from datetime import datetime # 1. Leer completo desde MySQL
query = "SELECT * FROM data_capeco_full WHERE ANIO='2025' AND TRIM='4T'" df = pd.read_sql(query, conn) # 2. Guardar como Parquet particionado path = f"bronze/capeco/raw/year=
df.to_parquet(path, index=False) # 3. Generar hash de integridad sha256 = hashlib.sha256(open(path,
manifest = {"rows":
```

```
len(df), "sha256":
sha256, "timestamp":
datetime.utcnow().isoform
"source":
"millennialprod.mysql.dat
# 4. Guardar
manifest.json junto al
parquet
```

- Formato: Apache Parquet (columnar, comprimido, compatible con Azure Synapse y Databricks)
- Inmutabilidad: política de retención de 7 años, sin permisos de delete en el contenedor Bronze
- Manifest: archivo JSON con COUNT, SHA256, timestamp y nombre de usuario que ejecutó la ingesta

B3

### Pipeline Bronze → Silver (limpieza y deduplicación)

Proceso automatizado que transforma el Bronze raw en Silver limpio: deduplicación, validación de tipos, enmascaramiento PII, normalización semántica básica.

**Días 10–17** **DE1**

**DoD: Silver tiene 0 duplicados por COD_PROYECTO+TRIM+ANIO · 0 GPS fuera de Lima**

TRANSFORMACIONES BRONZE → SILVER

- **Deduplicación:** COD_PROY + TRIM + ANI mantiene re más recient hay duplicac
- **Validación GPS:** X entre -77.2 y -76.7, Y entre -12.5 y -11.5 (bounding box Lima Metropolitana)
- **Normalización "No precisan":** MARCA_SAN MARCA_POR donde valor = precisan" / "N / "No tienen" estructurado
- **Tipos:** ANIO como integer, TRIM como string ("Q4"), GPS como float64
- **Enmascaramiento PII-2:** TELEFON PROPIET → hash SHA256 r reversible Silver
- **Campos con espacios:** renombrados en S usando snake_ca (NOMBRE DEL PROYECTO → nombre_del_proy

TRIGGER

- Manual en Sprint 1 (ejecución por DE1)
- Automático desde Sprint 2: Azure Data Factory o Apache Airflow — ejecuta 24h después de cada Bronze nuevo

B4

### Capa Silver validada

Datos limpios, tipados, sin duplicados y sin PII-2 expuesta. Validada por DataQualityAgent antes de pasar a Gold.

```
Días 12–18

DE1  construye ·
QA1  valida

DoD: reporte de
calidad
DataQualityAgent
con 0 errores
críticos
```

- QA valida: COUNT Silver ≤ COUNT Bronze (puede ser menor por dedup, nunca mayor)
- QA valida: 0 registros con X o Y = NULL en Silver
- QA valida: TELEFONO PROPIETARIO = NULL o hash en Silver (nunca

teléfono en claro)

- QA valida: ANIO y TRIM tienen tipos correctos (no strings vacíos)
- Reporte de calidad Silver generado automáticamente por DataQualityAgent (C2)

B5

### Pipeline Silver → Gold (certificación y métricas)

Proceso que genera la capa Gold: calcula métricas certificadas, aplica el schema registry, y separa los datos por producto.

Días 15–20

DE2

DoD: Gold generado · métricas Gold validan vs valores verificados manualmente

MÉTRICAS CALCULADAS EN GOLD (NO EXISTEN EN BRONZE)

- **PRECIO_X_M2:** PRECIO_SC / AREA_X_UN (ya existe er MySQL — se recalcula y

recalcula y valida)

- **ABSORCION_PCT:** UNIDAD NRO_UN × 100 (% unidade vendida
- **FASE_CODIGO:** codificació numérica d FASE para filtros rápidos
- **DISTRITO_NORM:** distrito no variantes mayúscul
- **GPS_VALID:** flag boolean — coordenadas dentro del bounding box Lima

SEPARACIÓN POR PRODUCTO

- gold/pme-capeco/ → todos los campos PII-0 + métricas Gold
- gold/pme-proveedores/ → subset aprobado en A4 (sin PII-1 hasta A10 firmado)

B6

### Capa Gold certificada

La fuente de verdad para todos los productos

los productos PME. Validada por QA, firmada por DE y lista para consumo por la API interna y los agentes.

**Días 17–20**

**DE2 · QA1 QA2**

**DoD: precio m² Gold de Miraflores = S/8,417 ±5% vs valor verificado de la BD**

- 163,914 registros históricos 2019–2025 disponibles
- 38,744 registros Q4 2025 como snapshot más reciente
- Precio m² Lima avg Gold: S/6,174 ±5% (verificado contra BD original)
- Absorción promedio Lima: 35.6% ±2% (verificado contra cálculo manual DA)
- Certificado con firma de DE2 en el manifest: "Gold v1.0 — Q4 2025 — LISTO

v1.0 — Q4 2025 — LISTO PARA PRODUCCIÓN"

B7

### API REST interna sobre Gold Layer

La API que reemplaza el acceso directo al MySQL de producción. Todos los productos PME y todos los agentes consumen datos a través de esta API — nunca directamente al MySQL.

**Días 5-15**

**FS1 FS2**

**DoD: latencia <200ms p95 · 100 users simultáneos sin degradación**

**ENDPOINTS PRINCIPALES**

```
GET /api/v1/obras ?distrito=Miraflores&fase=
?pct_avance_min=50&pct_ava
?limit=100&offset=0
Response: [{nombre_proyecto, fase, pct_avance, gps, pisos, ...}] GET /api/v1/obras/{cod_proyec
Response: ficha completa de la obra (campos según role del
```

```
token) GET
/api/v1/metricas/precio_m
?
distrito=Miraflores&anio=
Response:
{precio_m2_avg,
precio_m2_min,
precio_m2_max,
n_proyectos} GET
/api/v1/metricas/absorcic
?
distrito=Surco&anio=2025
Response:
{absorcion_pct_avg,
n_proyectos} POST
/api/v1/export/excel
body: {filtros,
campos_solicitados}
Response: archivo
.xlsx con campos
subset aprobado según
role
```

**STACK TÉCNICO**

- FastAPI (Python) o Express (Node) — a definir por FS1 según preferencia del equipo
- Cache con Redis: queries frecuentes cacheadas 15 minutos
- Auth: JWT Bearer tokens con claims de role (del RBAC A5)
- Rate limiting: 100 req/min por token
- Documentación automática: Swagger/OpenAPI generada por FastAPI

generado por FastAPI

B8

### Snapshots trimestrales inmutables con versionado

Sistema de versionado que garantiza que siempre se puede reproducir el estado exacto de la BD en cualquier trimestre pasado.

Días 8–14 DE2

DoD: snapshot Q4-2025 restaurable desde Bronze con hash verificable

- Nomenclatura: capeco_bronze_YYYY_QN_v
  capeco_bronze_YYYY_QN_v
- Manifest incluye: rows, sha256, timestamp, usuario, versión de schema, versión del pipeline
- Política: una vez escrito, el archivo Bronze no puede ser modificado ni eliminado (Azure immutable blob policy)
- Historial disponible: Q1–2019 a Q4–2025 (163,914 registros totales)

B9

## Dashboard admin de governance

Interfaz web visible para el equipo técnico MIS y para CAPECO que muestra el estado de salud del Data Lake en tiempo real.

Días 10–18

FS3

DoD: CAPECO puede ver completitud, linaje y SLAs sin necesitar acceso técnico

- Panel de completitud: % de cada campo Gold vs SLA definido en A8 — semáforo verde/amarillo/rojo
- Panel de linaje: árbol de transformaciones Bronze→Silver→Gold para cada campo
- Panel de audit log: últimos accesos a campos PII con usuario y timestamp
- Panel de agentes: estado de última ejecución de DataQualityAgent, NormalizationAgent, LineageAgent
- Panel de snapshots:

listado de versiones Bronze disponibles con hash y fecha

→ Este dashboard es el que CAPECO verá en vivo durante la demo del Día 60

C · AGENTES · 8 ENTREGABLES · DÍAS 1–52

## Arquitectura de agentes sobre el Data Lake

Los agentes son procesos Python autónomos que leen del Data Lake, ejecutan una lógica específica y escriben resultados estructurados. No son chatbots. Cada uno tiene un único objetivo, inputs definidos, outputs verificables y manejo de errores explícito.

🏗️ **Principio de diseño de los agentes PME:** Cada agente es un proceso Python con 4 secciones fijas: (1) validate_inputs(), (2) execute(), (3) validate_outputs(), (4) log_result(). Si cualquier sección falla, el agente termina con error controlado y genera un log JSON — nunca se propaga silenciosamente un dato incorrecto a la capa Gold.

C1

### Diseño de arquitectura de agentes

Documento que define la interface común de todos los agentes, el protocolo de comunicación entre ellos y la arquitectura del orquestador.

Días 1–5

DE1 FS1

DoD: aprobado por todo el equipo técnico antes del Día 5

INTERFACE BASE DE TODOS LOS AGENTES (PYTHON)

```
from abc import ABC,
abstractmethod from
dataclasses import
dataclass from
datetime import
datetime import json,
logging @dataclass
class AgentResult:
agent_name: str
status: str #
"success" | "warning"
| "error" timestamp:
str inputs_hash: str #
SHA256 de los inputs
outputs: dict #
resultado estructurado
errors: list # lista
de errores encontrados
warnings: list # lista
de advertencias
metrics: dict #
métricas de ejecución
class BaseAgent(ABC):
def run(self) ->
AgentResult: try:
self.validate_inputs()
# Falla rápido si
inputs incorrectos
result =
self.execute() #
Lógica principal del
agente
self.validate_outputs(res
# Valida que outputs
son correctos return
self.log_result(result,
"success") except
Exception as e: return
self.log_result({},
"error", error=str(e))
@abstractmethod def
```

```
validate_inputs(self):
... @abstractmethod
def execute(self) ->
dict: ...
@abstractmethod def
validate_outputs(self,
result: dict): ...
```

PRINCIPIOS DE DISEÑO

- Idempotencia: ejecutar el agente dos veces con los mismos inputs produce el mismo resultado
- Fail-fast: si validate_inputs() falla, el pipeline no continúa — no se propaga data incorrecta
- Observabilidad: cada ejecución genera un log JSON con timestamp, inputs_hash, métricas y errores
- Independencia: cada agente puede ejecutarse solo — sin dependencia en memoria compartida

C2

### DataQualityAgent v1 🔍

Agente que valida cada carga Bronze antes de permitir el paso a Silver. Es el guardián de la calidad: si falla, el pipeline se detiene.

Días 12–18

DE1 DE2

DoD: detecta GPS inválidos, precios outlier y duplicados. Genera reporte JSON.

VALIDACIONES IMPLEMENTADAS

- **GPS Lima:** X en [-77.2, -76.7], Y en [-12.5, -11.5] — rechaza registros fuera de Lima
- **Precio m² outlier:** PRECIO_X_M2 fuera de [S/1,000, S/25,000] → warning, no error (pueden ser casos reales)
- **Duplicados:** COD_PROYEC + TRIM + ANIO duplicados → error crítico, bloquea pipelin
- **Completitud Core:** campos Core bajo SLA definido en A8 → warning si >5% degradación respecto al trimestre anterior
- **Tipos:** ANIO y TRIM tienen formato correcto ('2025',

'Q4') → error si no

→ **PII-2 expuesto:** TELEFONO PROPIETARIO en claro en Silver → error crítico

OUTPUT DEL AGENTE (JSON)


```
{ "agent": "DataQualityAgent", "status": "success" | "warning" | "error", "timestamp": "2026-04-05T14:32:00Z", "snapshot": "capeco_bronze_2025_Q4_v1 "metrics": { "total_rows": 38744, "duplicados": 0, "gps_invalidos": 0, "precio_outliers": 12, "campos_bajo_sla": [] }, "errors": [], "warnings": ["12 registros con PRECIO_X_M2 > S/20,000 — revisar"], "pipeline_proceed": true }
```


C3

### NormalizationAgent v1

Estandariza valores semánticamente equivalentes. El problema central: "TREBOL", "Trébol", "trebol s.a.", "TREBOL

SA" son la misma marca — el agente lo resuelve.

**Días 14–19** FS1

**DoD: "Trébol" aparece con un solo valor normalizado en Silver. Diccionario actualizable sin código.**

CAMPOS NORMALIZADOS EN V1

- **MARCA_SANITARIO:** 30+ va → 5 ma reales Vainsa Caribe Edesa para "N precis inform
- **MARCA_PORCELANATO:** va C L K In + "N
- **MARCA_DRYWALL:** variante → Gyplac Vocaloi Knauf + NULL
- **DISTRITO:** "Santiago De

| | |
|---|---|
| | Surco", "Stgo. de Surco", "SURCO" → "Santiago de Surco" (forma canónica INEI) |
| → **NOMBRE DEL CONSTRUCTOR:** | "SENDA", "Senda Inmobiliari "SENDA SAC" → "Senda Inmobiliari S.A.C." (so si A10 firmado) |

**DICCIONARIO DE ALIASES (ACTUALIZABLE SIN CÓDIGO)**

```
# aliases.json — mantenido por DA, no requiere developer {
"MARCA_SANITARIO": {
"canonical": {
"Trébol": ["TREBOL", "trebol", "Trebol S.A.", "TREBOL SA"],
"Vainsa": ["VAINSA", "vainsa", "Vainsa Perú"] },
"null_values": ["No precisan", "No informa", "Sin marca", "0", ""] } }
```

- Claude API apoya la generación inicial del diccionario: DA sube el top-50 valores frecuentes por campo y Claude sugiere la

normalización

→ DA revisa y aprueba — el archivo aliases.json es mantenido por DA sin tocar código

C4

## LineageAgent v1

Registra automáticamente cada transformación Bronze→Silver→Gold con timestamp, versión y diferencias de schema. Responde la pregunta: ¿de dónde viene este dato?

**Días 15–20** FS2

**DoD: dado el precio m² de Miraflores Gold, se puede trazar hasta Bronze en <3 clicks en B9**

QUÉ REGISTRA POR CADA TRANSFORMACIÓN


```
{ "lineage_event": {
"event_id":
"evt_20260405_143200",
"timestamp": "2026-04-
05T14:32:00Z",
"from_layer":
"bronze", "to_layer":
"silver",
"snapshot_in":
"capeco_bronze_2025_Q4_v1
```

```
"snapshot_out":
"capeco_silver_2025_Q4_v1
"rows_in": 38744,

"rows_out": 38721, ←
23 duplicados
eliminados
"transformations": [
"dedup_by_cod_proyecto_tr
"gps_validation",
"pii2_masking",
"null_normalization"
], "schema_diff": [],
← vacío si no cambió
schema "executed_by":
"pipeline_bronze_silver_v
} }
```


- Todos los eventos se escriben en una tabla append-only en Azure SQL o en el contenedor gold/lineage/
- Visible en el dashboard B9 como árbol de transformaciones
- Si schema cambia entre trimestres, genera alerta al equipo técnico

C5

### Orquestador de agentes

El pipeline completo que encadena los agentes en el orden correcto. Define las dependencias entre agentes y

entre agentes y maneja los errores de cada uno.

**Días 16–20**

**FS1** **DE1**

**DoD: pipeline completo ejecuta de punta a punta en <30 min para 38,744 registros**

**PIPELINE COMPLETO DE INGESTA**

```
# Orquestador — ejecución secuencial con fail-fast
PIPELINE: ingesta_trimestral_capeco
PASO 1: BronzeIngesta
Input: MySQL db_capeco.data_capeco_ful
(ANIO, TRIM específico) Output: bronze/capeco/raw/year=YY
Error: STOP — no continuar si falla la ingesta PASO 2: DataQualityAgent
Input: snapshot Bronze recién creado Output: quality_report.json
Error: STOP si status = "error" · CONTINUE si status = "warning"
PASO 3: BronzeToSilverPipeline
Input: snapshot Bronze + quality_report.json
Output: silver/capeco/cleaned/yea

Error: STOP si pipeline falla PASO 4:
```

```
pipeline falla PASO 4:
NormalizationAgent
Input: capa Silver +
aliases.json Output:
silver normalizado in-
place Error: WARN (no
bloquea) — dato sin
normalizar pasa como
está PASO 5:
SilverToGoldPipeline
Input: Silver
normalizado +
schema_registry.json
Output: gold/pme-
capeco/ + gold/pme-
proveedores/ Error:
STOP si pipeline falla
PASO 6: LineageAgent
Input: eventos de cada
paso anterior Output:
lineage_events
escritos en
gold/lineage/ Error:
WARN — no bloquea
(lineage es
observabilidad, no
crítico) PASO 7:
Notificación Output:
email al equipo con
resumen del pipeline
```

**TECNOLOGÍA DEL ORQUESTADOR**

- Sprint 1: script Python simple con llamadas secuenciales — funcional para la demo
- Sprint 2+: Azure Data Factory o Apache Airflow con DAG para ejecución automática y monitoreo

C6

### Test suite de agentes (Sprint 1)

Suite de pruebas unitarias e integración para los 3 agentes del Sprint 1. Cobertura mínima 80% con casos borde específicos del dominio CAPECO.

Días 17–20

QA1 QA2

DoD: pytest pasa al 100% · CI/CD falla si cobertura baja de 80%

CASOS DE TEST OBLIGATORIOS POR AGENTE

- **DataQualityAgent:** GPS en Lima ✓, GPS fue de Lima, precio outlier → warning, duplicac → error, campo PII-2 en claro → error crítico
- **NormalizationAgent:** "TREB "Trébo "No precis

| | |
|---|---|
| | NULL, y no en diccio → pasa cambi alias.js malfor → error contro |
| **LineageAgent:** | evento escrit correctamer schema diff detectado, fallo de escritura → warning sin bloquear pipeline |
| **Orquestador:** | fallo en PASO 2 → pipeline se detiene en PASO 3, fallo en PASO 6 → pipeline continúa con warning |

### GENERACIÓN DE CASOS CON CLAUDE

- QA usa Claude para generar el 70% de los test cases a partir de la especificación de cada agente (C1)
- QA revisa, ajusta y agrega los casos borde

los casos borde específicos del dominio CAPECO que Claude no conoce

C7

### AlertAgent v1 (Sprint 2 · Días 21–30)

Detecta obras nuevas en cada carga trimestral y envía notificaciones por zona y fase configurada por cada suscriptor de PME Proveedores.

Sprint 2 · Días 21–30

DE1 FS3

DoD: email de alerta enviado con obras nuevas en zona configurada. QA valida que no hay falsos positivos.

- Compara Gold Q_actual vs Gold Q_anterior: proyectos con COD_PROYECTO nuevo = obra nueva
- Filtra por configuración del suscriptor: distritos de interés + fases de avance de su categoría
- Email semanal con lista de obras nuevas: nombre, distrito, piso, fase

distrito, pisos, fase, contacto (si A10 firmado)

- Canal alternativo: webhook a CRM del suscriptor (plan PRO y Enterprise)

C8

### ReportAgent v1 (Sprint 3 · Días 46–52)

Genera el reporte trimestral PME en PDF automáticamente desde la capa Gold. El Día 60 CAPECO lo verá generarse en vivo durante la demo.

Sprint 3 · Días 46–52

DE1 DE2

DoD: PDF de 10 páginas generado en <60 segundos desde Gold. Datos verificados por DA.

- Secciones del PDF: precio m² por distrito top 10, absorción por segmento, stock disponible, obras nuevas vs trimestre anterior, marcas líderes (Gold donde hay datos)
- Template: Python + WeasyPrin ReportLab — mismo stack qu

Brochure_PME_CAPECO_20
ya generado

- Personalizable por suscriptor: distritos de interés filtrados en el reporte
- Firma digital: "Datos certificados CAPECO × MIS — Q4 2025" en el footer
- En la demo Día 60: DA ejecuta el agente en vivo, el PDF se genera en pantalla ante CAPECO